INSTITUTO DE FÍSICA DE SÃO CARLOS
UNIVERSIDADE DE SÃO PAULO

INTRODUÇÃO À MODELAGEM MATEMÁTICA EM BIOLOGIA

O mapa seno — projeto 2

Nome: Joenyr P. C. Domingues
NUSP: 15464382

São Carlos
06/04/2026

Índice

Introdução **3**

1 Desenvolvimento **4**
1.1 Diagrama de Bifurcação 4
1.2 Estimativa Numérica do Expoente de Lyapunov 5
1.3 Distribuição da Variável (X_t) no Caos 6

Conclusão **7**

Referências **8**

Apêndice: Códigos Fontes **9**
Código 1: funções e variáveis globais 9
Código 2: Diagrama de bifurcação 9
Código 3: Expoente de Lyapunov 10
Código 4: Distribuição no caos 11

Introdução

A modelagem matemática em biologia frequentemente emprega equações de diferenças para descrever a evolução temporal de populações ou de sistemas dinâmicos, como discutido por Allman e Rhodes (2004) no Capítulo 1 de seu livro *Mathematical Models in Biology: An Introduction*. Enquanto o modelo Malthusiano linear $P_{t+1} = \lambda P_t$ produz crescimento ou decaimento exponencial, modelos não lineares, como o mapa logístico, revelam comportamentos mais ricos, incluindo bifurcações e caos. Neste projeto, explora-se o mapa seno, definido pela equação de recorrência

$$x_{t+1} = A \sin(\pi x_t), \tag{1}$$

onde $x_t \in [0, 1]$ e o parâmetro de controle $A \in (0, 1]$. Este mapa, embora simples, exibe uma dinâmica complexa análoga à do mapa logístico, sendo utilizado para ilustrar conceitos fundamentais da teoria de sistemas dinâmicos.

Para analisar o mapa seno, emprega-se três ferramentas computacionais que seguem a metodologia. A primeira é o diagrama de bifurcação, que consiste em variar o parâmetro A e, para cada valor, descartar um número suficiente de iterações iniciais (transiente) e então plotar os valores subsequentes de x_t em função de A. Esse gráfico revela como o comportamento de longo prazo do sistema muda com A: regiões de ponto fixo, ciclos de período 2, 4, 8, e regimes caóticos, além de janelas de periodicidade dentro do caos. A análise de bifurcações é essencial para compreender a transição da ordem ao caos em modelos não lineares discretos.

A segunda ferramenta é o expoente de Lyapunov, que quantifica a sensibilidade do sistema às condições iniciais. Para o mapa seno, a derivada da função é $f'(x) = A\pi \cdot \cos(\pi x)$. O expoente é estimado numericamente por

$$\lambda \approx \frac{1}{N} \sum_{i=1}^{N} \ln |f'(x_i)|, \tag{2}$$

onde os x_i são pontos de uma órbita após o transiente. Valores de λ negativos indica-se estabilidade periódica, $\lambda \approx 0$ ocorre nos pontos de bifurcação, e $\lambda > 0$ caracteriza caos. Allman e Rhodes (2004) destacam que o expoente de Lyapunov é uma medida direta da imprevisibilidade em sistemas caóticos, sendo calculado por meio da linearização da dinâmica.

A terceira etapa consiste em investigar a distribuição da variável x_t no regime caótico, escolhe-se um valor de A com $\lambda > 0$ (por exemplo, $A = 0,98$). Gerando uma série temporal longa (como 10^6 iterações) e construindo um histograma, obtem-se uma estimativa da densidade de probabilidade invariante do mapa. Essas três abordagens – diagrama de bifurcação, expoente de Lyapunov e análise da densidade – fornecem uma caracterização completa da dinâmica do mapa seno, onde se ilustra a aplicação de métodos matemáticos e computacionais em problemas biológicos.

1 Desenvolvimento

1.1 Diagrama de Bifurcação

Para construir o diagrama de bifurcação do mapa seno, implementou-se uma rotina que varre o parâmetro A no intervalo $[0.6, 1.0]$ com passo $\Delta A = 0.001$. Para cada valor de A, a equação de recorrência é iterada a partir de uma condição inicial aleatória $x_0 \in [0, 1]$. Descarta-se os primeiros 1000 iterados como transiente, e então os próximos 500 valores de x_t são armazenados e plotados contra o respectivo A. Utilizou-se transparência baixa (alpha = 0.13) nos pontos para evidenciar regiões de maior densidade. A Figura Fig. 1 apresenta o diagrama obtido, onde é possível identificar as diferentes fases do sistema.

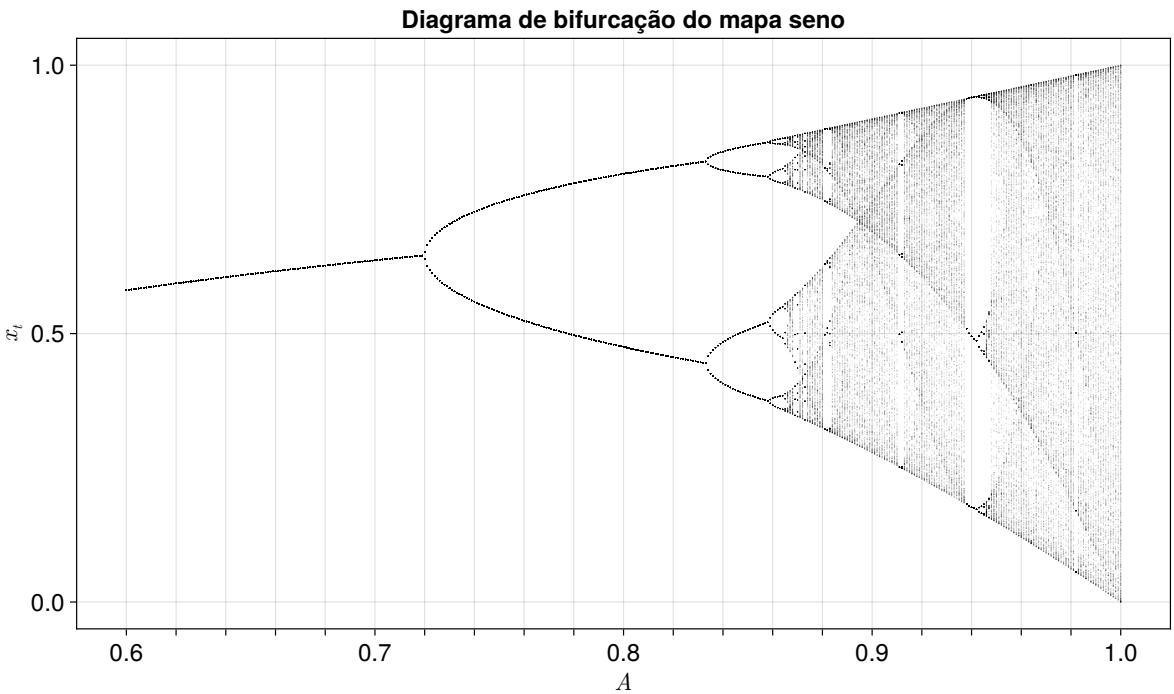

Figura 1: Diagrama de bifurcação do mapa seno para $A \in [0.6, 1.0]$. Código

A análise visual do diagrama de bifurcação permitiu identificar claramente as diferentes regiões do Diagrama. Para A entre aproximadamente em 0.72, o sistema converge para um ponto fixo estável (ramo único). Após este ponto, temos a primeira bifurcação, dando origem a um ciclo de período 2, que persiste até $A \approx 0.84$. Após $A \approx$ temos um ciclo de 8. Sucessivas duplicações de período levam a ciclos de período 4 e 8 em intervalos cada vez mais estreitos, culminando em uma região caótica a partir de $A \approx 0.87$. Dentro do caos, observam-se janelas de periodicidade, podemos ver próximos à $A \approx 0.88$, $A \approx 0.92$ e $A \approx 0.94$. Com incerteza visual de ± 0.02 (relativo às divisões do gráfico).

1.2 Estimativa Numérica do Expoente de Lyapunov

O expoente de Lyapunov quantifica a sensibilidade às condições iniciais. Para o mapa seno, a derivada da função é $f'(x) = A\pi \cdot \cos(\pi x)$. O expoente é estimado por $\lambda \approx \frac{1}{N}\sum_{i=1}^{N} \ln|f'(x_i)|$, onde os x_i pertencem a uma órbita após o transiente. Implementou-se o cálculo para cada A com $N = 5000$ e descarte de 1000 iterações iniciais. A Figura Fig. 2 mostra λ em função de A, alinhada verticalmente com o diagrama de bifurcação.

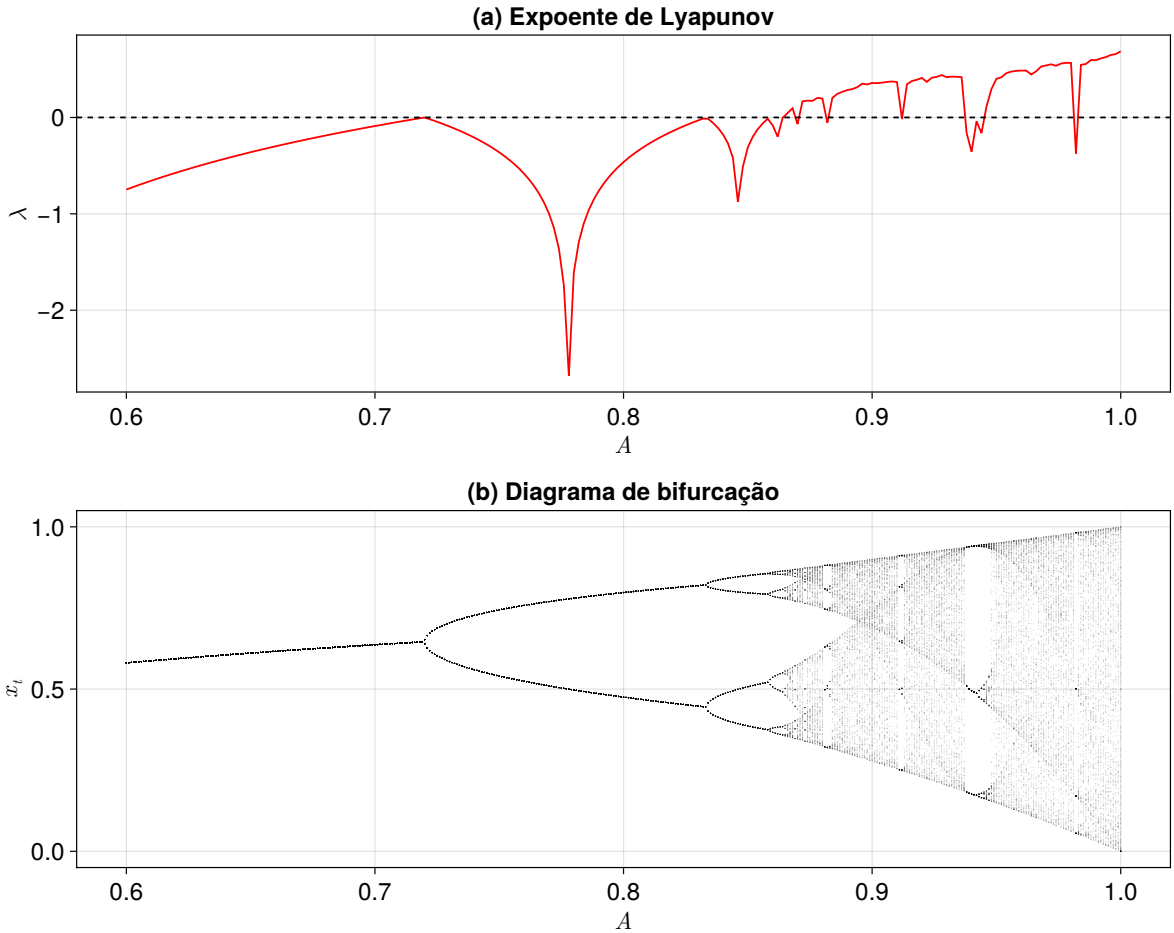

Figura 2: Onde, (a) Expoente de Lyapunov λ em função de A e (b) diagrama de bifurcação correspondente. Código

Os resultados confirmam as relações esperadas: $\lambda < 0$ nas regiões periódicas (ponto fixo e ciclos), $\lambda \approx 0$ nos pontos de bifurcação (onde ocorre a duplicação de período) e $\lambda > 0$ nas regiões caóticas. Por exemplo, para $A = 0.7$ e $A = 0.8$ (ponto fixo) $\lambda < 0$; em $A \approx 0.72$ e $A \approx 0.84$ (primeira e segunda bifurcação) λ cruza zero; e para $A = 0.9$ (caos) $\lambda > 0$. As janelas periódicas dentro do caos aparecem icomo vales negativos pronunciados, como em $A \approx 0.94$, onde λ torna-se negativo.

1.3 Distribuição da Variável (X_t) no Caos

Escolheu-se $A = 0.98$, valor situado em uma região caótica conforme o expoente de Lyapunov positivo ($\lambda \approx 0.2$). Gerou-se uma série temporal de 10^6 iterações após descarte de 1000 transientes. A Figura Fig. 3 mostra o histograma normalizado desses valores com 200 bins, aproximando a densidade de probabilidade invariante do mapa.

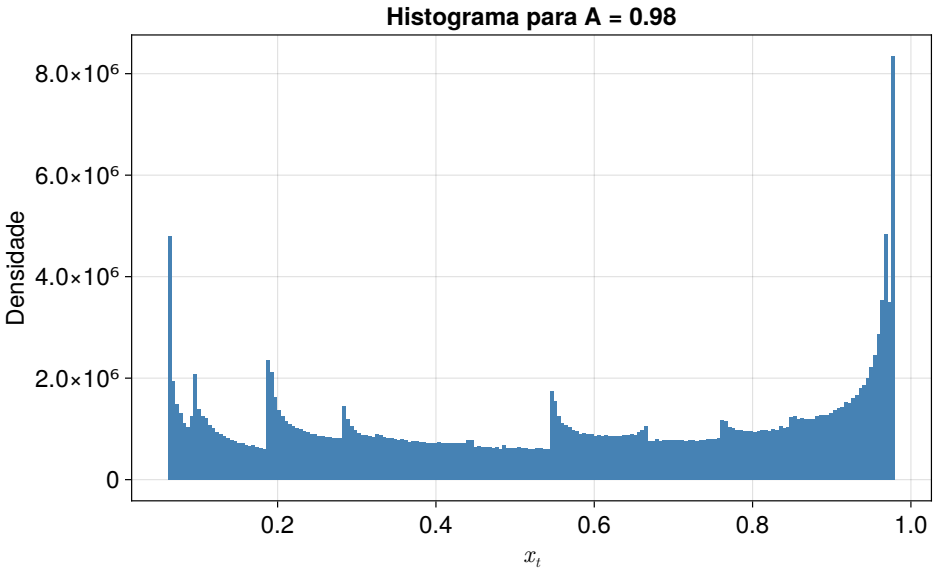

Figura 3: Distribuição da variável x_t para $A = 0.98$ (regime caótico). Código

O histograma não é uniforme; apresenta picos pronunciados em certas regiões do intervalo $[0, 1]$, e vales onde a densidade é muito baixa, por exemplo, o primeiro e o último picos mais expressivos e isolados demonstram alta densidade. Isso indica que, mesmo no caos, a órbita não visita todos os pontos com igual probabilidade, mas se concentra em subconjuntos atratores que refletem a forma não linear do mapa. A distribuição não mostra "buracos" expressivos como viu-se nos picos, mas é possível notar concavidades expressas como vale, está associada à presença de pontos instáveis ou à repulsão por ciclos periódicos instáveis.

Conclusão

A análise do mapa seno $x_{t+1} = A\sin(\pi x_t)$ realizada neste trabalho permitiu caracterizar quantitativamente sua rica dinâmica para o parâmetro $A \in [0,6, 1,0]$.

O diagrama de bifurcação revelou a clássica rota para o caos via duplicação de período, com pontos fixos estáveis para A abaixo de aproximadamente $0,72$, ciclos de período 2 até $0,84$, e subsequentes duplicações até o estabelecimento do comportamento caótico a partir de $A \approx 0,87$, intercalado por janelas de periodicidade como as observadas próximas a $A \approx 0,88$, $0,92$ e $0,94$. O expoente de Lyapunov confirmou essas transições, sendo negativo nas regiões periódicas, próximo de zero nos pontos de bifurcação e positivo no regime caótico, com vales negativos nas janelas periódicas, validando a interpretação do expoente como medida de sensibilidade às condições iniciais.

Por fim, a distribuição da variável x_t para $A = 0,98$ mostrou que, mesmo no caos a órbita não é uniforme: o histograma exibe picos pronunciados e vales, indicando que a medida invariante se concentra em subconjuntos atratores, refletindo a não linearidade do mapa e a ausência de ergodicidade uniforme.

Esses resultados, em consonância com a teoria de sistemas dinâmicos apresentada por Allman e Rhodes (2004), demonstram como ferramentas computacionais simples podem desvendar estruturas complexas em modelos matemáticos de relevância biológica, como em estudos de populações com dinâmica não linear e sensibilidade a parâmetros.

Referências

[1] ALLMAN, E. S.; RHODES, J. A. **Mathematical models in biology: An introduction**. Cambridge: Cambridge University Press, 2004.

[2] IFSC - INSTITUTO DE FÍSICA DE SÃO CARLOS. **7600132 - Introdução à Modelagem Matemática em Biologia: O mapa seno (parte 2)**. São Carlos.Universidade de São Paulo, 2026. Disponível em: <https://edisciplinas.usp.br/course/view.php?id=137935>. Acesso em: 6 abr. 2026

Apêndice: Códigos Fontes

Código 1: funções e variáveis globais

```
using CairoMakie, Logging
# ajusta tamanhos globais de imagens
set_theme!(Theme(fontsize = 20,
                 titlesize = 20,
                 xlabelsize = 18,
                 ylabelsize = 18,
                 ticklabelsize = 16))
# define o mapa seno e sua derivada
f(A, x) = A * sin(  * x)
df(A, x) = A *   * cos(  * x)
alpha = 0.13 # opacidade do diagrama
pointsize = 1.5 # tamanho dos pontos
nothing
```

Código 2: Diagrama de bifurcação

```
pdf_path = "bifurcacao.pdf"
A_vals = 0.6:0.001:1.0
transiente = 1000
amostra = 500
x0 = rand()
x_points = Float64[]
A_points = Float64[]
for A in A_vals
    x = x0
    for _ in 1:transiente
        x = f(A, x)
    end
    for _ in 1:amostra
        x = f(A, x)
        push!(x_points, x)
        push!(A_points, A)
    end
end
# Posições dos ticks (linhas de grade) a cada 0.02
ticks_pos = 0.6:0.02:1.0
# Rótulos: apenas para valores múltiplos de 0.1, caso contrário string
 ↪  vazia
ticks_labels = [if round(x, digits=1) == x string(round(x, digits=2))
 ↪  else "" end for x in ticks_pos]
with_logger(Logging.SimpleLogger(stderr, Logging.Error)) do
    global fig = Figure(resolution=(1000,600))
```

```
    ax = Axis(fig[1,1], xlabel = L"A", ylabel = L"x_t", xticks =
 ↪  (ticks_pos, ticks_labels),
              title = "Diagrama de bifurcação do mapa seno")
    scatter!(ax, A_points, x_points, markersize=pointsize, color=:black,
     ↪  alpha=alpha)
    save(pdf_path, fig)
end
md = "![](" * pdf_path * ){#fig-bifurcacao width=100%}"
display(MIME("text/markdown"), md)
```

Geração do diagrama de bifurcação com descarte de transiente.
↩ Voltar para a figura

Código 3: Expoente de Lyapunov

```
pdf_path = "lyapunov.pdf"
A_vals = 0.6:0.002:1.0
transiente = 1000
N = 5000
x0 = rand()
lambda_vals = Float64[]
for A in A_vals
    x = x0
    for _ in 1:transiente
        x = f(A, x)
    end
    sum_ln = 0.0
    for _ in 1:N
        x = f(A, x)
        sum_ln += log(abs(df(A, x)))
    end
    push!(lambda_vals, sum_ln / N)
end
A_bif = 0.6:0.001:1.0
x_points_bif = Float64[]
A_points_bif = Float64[]
for A in A_bif
    x = x0
    for _ in 1:transiente
        x = f(A, x)
    end
    for _ in 1:200
        x = f(A, x)
        push!(x_points_bif, x)
        push!(A_points_bif, A)
    end
end
```

```
with_logger(Logging.SimpleLogger(stderr, Logging.Error)) do
    global fig = Figure(resolution=(1000,800))
    ax1 = Axis(fig[1,1], xlabel = L"A", ylabel = L"\lambda",
               title = "(a) Expoente de Lyapunov")
    lines!(ax1, A_vals, lambda_vals, color=:red, linewidth=1.5)
    hlines!(ax1, 0, color=:black, linestyle=:dash)
    ax2 = Axis(fig[2,1], xlabel = L"A", ylabel = L"x_t",
               title = "(b) Diagrama de bifurcação")
    scatter!(ax2, A_points_bif, x_points_bif, markersize=pointsize,
     ↪  color=:black, alpha=alpha)
    save(pdf_path, fig)
end
md = "![](" * pdf_path * ){#fig-lyapunov width=100%}"
display(MIME("text/markdown"), md)
```

Cálculo do expoente de Lyapunov e visualização combinada.
↩ Voltar para a figura

Código 4: Distribuição no caos

```
pdf_path = "histograma.pdf"
A_caos = 0.98
transiente = 1000
N_hist = 10^6
x = rand()
for _ in 1:transiente
    x = f(A_caos, x)
end
dados = Float64[]
for _ in 1:N_hist
    x = f(A_caos, x)
    push!(dados, x)
end
with_logger(Logging.SimpleLogger(stderr, Logging.Error)) do
    global fig = Figure(resolution=(800,500))
    ax = Axis(fig[1,1], xlabel = L"x_t", ylabel = "Densidade",
              title = "Histograma para A = $A_caos")
    hist!(ax, dados, bins=200, normalization=:density, color=:steelblue)
    save(pdf_path, fig)
end
md = "![](" * pdf_path * ){#fig-histograma width=80%}"
display(MIME("text/markdown"), md)
```

Histograma de dez à sexta potência iterados após transiente.
↩ Voltar para a figura